

HIERARCHISCHES CLUSTERING

Wenn K unbekannt ist

Präsentiert von Jeanne Lauper

Modul: Data Science FS/26

01


DAS K-PROBLEM

K-Means setzt voraus, dass K bekannt ist, aber was, wenn wir K nicht kennen?



Unbekannte Struktur

Reale Daten haben oft keine offensichtliche Anzahl von Gruppen.



K muss vorab gewählt werden

K-Means verlangt K als Eingabe – eine willkürliche Entscheidung.




Lösung: Hierarchisch

Baut einen vollständigen Clusterbaum – K kann danach gewählt werden.

KERNIDEE: DER STAMMBAUM DER DATEN

Analogie: Familienstammbaum

- 1 Start: Alice, Bob, Carol, Dave — jeder für sich
- 2 Schritt 1: Alice & Bob ähnlichsten → Familie 1
- 3 Schritt 2: Carol & Dave ähnlichsten → Familie 2
- 4 Schritt 3: Familie 1 & 2 → Clan
- 5 Ergebnis: Vollständiger Baum ohne K festzulegen



AGGLOMERATIVER ALGORITHMUS

Agglomerativ = „von unten nach oben“

1

Initialisierung

Jeder Datenpunkt bildet seinen eigenen Cluster → N Cluster

2

Abstände berechnen

Erstelle eine vollständige Abstandsmatrix für alle Clusterpaarungen

3

Nächste zusammenführen

Finde die zwei ähnlichsten Cluster und verschmelze sie zu einem

4

Matrix aktualisieren

Berechne neue Abstände zwischen dem Merged-Cluster und allen anderen

5

Wiederholen

Wiederhole Schritte 3–4 bis nur noch 1 Cluster übrig bleibt

Ergebnis: Vollständiger Clusterbaum (Dendrogram) — K kann danach frei gewählt werden

LINKAGE-METHODEN: WIE MESSEN WIR ÄHNLICHKEIT?

Wie misst man den Abstand zwischen zwei Gruppen — nicht nur zwei Punkten?

Single Linkage

$$\min d(a,b)$$

Abstand der nächsten Punkte zweier Cluster. Neigt zur Kettenbildung (chaining).

+ Findet nicht-konvexe Formen

– Anfällig für Ausreißer

Complete Linkage

$$\max d(a,b)$$

Abstand der fernsten Punkte zweier Cluster. Erzeugt kompakte, gleich grosse Cluster.

+ Robuster gegen Ausreißer

– Bricht grosse Cluster auf

Average Linkage

$$\text{avg } d(a,b)$$

Durchschnitt aller paarweisen Abstände zwischen den Clustern.

+ Guter Kompromiss

– Kein klares Kriterium

Ward-Methode

$$\min \Delta\text{Var}$$

Minimiert den Anstieg der Within-Cluster-Varianz. Empfohlener Standard.

+ Ausgewogene Cluster

– Nur euklidische Dist.

★ EMPFOHLEN

WARD-METHODE IM DETAIL

Prinzip: Führe zwei Cluster zusammen, wenn der Anstieg der Within-Cluster-Varianz minimal ist.

FORMEL

$$d_{\text{ward}}(A,B) = \sqrt{2 \cdot |A| \cdot |B| / (|A| + |B|)} \times ||\mu_A - \mu_B||$$

$|A|, |B|$

Anzahl der Punkte in Cluster A und B
— grössere Cluster werden
berücksichtigt

μ_A, μ_B


Schwerpunkte (Zentroide) der Cluster
— misst, wie weit sie
auseinanderliegen

Ziel

Nur zusammenführen, wenn die
Varianzerhöhung möglichst klein bleibt
→ ausgewogene Cluster

Single / Complete / Average: Bei spezifischen Anforderungen an Clusterform, -dichte oder nicht-euklidischen Distanzen.

DAS DENDROGRAMM LESEN



X-Achse

Beobachtungen (Datenpunkte)

Y-Achse

Merge-Distanz — je höher, desto unähnlicher

Horizontale Linien

Zeitpunkt der Zusammenführung zweier Cluster

Breite Lücken


Natürliche Cluster-Grenzen im Datensatz

Horizontaler Schnitt

Legt die Anzahl K der Cluster fest

DEN BAUM SCHNEIDEN: K WÄHLEN

Faustregel: Schneide unterhalb der längsten „Astgabel“ im Dendrogram




Visuelle Methode

Größte Lücke (gap) im Dendrogram suchen.
Ähnlich wie der Elbow bei K-Means.




Silhouette-Koeffizient

Misst Kohäsion und Separation.
Wert nahe +1 = gut getrennte Cluster.



Domänenwissen

Fachliche Plausibilität der Clusteranzahl.
Oft die praktisch wichtigste Methode.



Inkonsistenz

Statistische Auswertung der Merge-Abstände.
Sucht ungewöhnlich große Sprünge.

Tipp: In der Praxis kombiniert man visuelle Inspektion + Silhouette + Domänenwissen für die beste Entscheidung.

HIERARCHISCH VS. K-MEANS

Kriterium	K-Means	Hierarchisches Clustering
K vorab nötig?	Ja – muss bestimmt werden	Nein – K wird danach gewählt
Komplexität	$O(n \cdot k \cdot t)$ schnell	$O(n^2)$ langsam bei grossen n
Clusterformen	Nur konvexe (runde) Cluster	Beliebige Formen möglich
Reproduzierbarkeit	Zufällige Initialisierung	Deterministisch
Visualisierung	Keine direkte Struktur	Dendrogram zeigt alle Ebenen
Typische Anwendung	Grosse Datensätze, bekanntes K	Explorative Analyse, kleines n

Empfehlung: Hierarchisch für Exploration & Strukturverständnis — K-Means für Skalierung & Produktion

PRAXISANWENDUNG: HIERARCHICAL RISK PARITY (HRP)

Lopez de Prado (2016) · Journal of Portfolio Management

1

Problem

Klassische Markowitz-Optimierung ist instabil bei korrelierten Assets (Matrixinversion).

2

Distanzmaß

Abstand zwischen Assets: $d = 1 - \rho$
(ρ = Korrelation der Renditen, 0 = identisch, 1 = unkorreliert)

3

Clustering

Hierarchisches Clustering der Assets nach Renditekorrelation → Dendrogram der Portfoliostruktur

4

Risikoallokation

Innerhalb von Clusters: Risikogewichtung umgekehrt proportional zur Varianz jedes Assets

5

Vorteil


Kein Matrixinversions-Problem · Robuster als Markowitz · Nutzt natürliche Clusterstruktur

Datensatz: 6 Familienmitglieder nach Alter (Jahre) und Körpergröße (cm)

Name	Alter (J.)	Größe (cm)
Oma	72	162
Opa	75	178
Mama	45	168
Papa	48	182
Lena	12	148
Max	10	142

- Cluster 1: Grosseltern (älter, grösser)
- Cluster 2: Eltern (mittel, grösser)
- Cluster 3: Kinder (jung, kleiner)

Ergebnis-Dendrogram (Ward-Linkage)



12

Ward-Linkage trennt klar: Grosseltern | Eltern | Kinder - ohne K vorab festzulegen!

PYTHON-IMPLEMENTIERUNG

scipy — Visualisierung & Flexibilität

```
from scipy.cluster.hierarchy import (
    linkage, dendrogram, fcluster
)

# 1. Linkage-Matrix berechnen
Z = linkage(X, method='ward')

# 2. Dendrogram visualisieren
dendrogram(Z, labels=names)
plt.show()

# 3. Cluster-Zuordnung erzeugen
labels = fcluster(
    Z, t=3,
    criterion='maxclust'
)
```

sklearn — Pipeline-Integration

```
from sklearn.cluster import (
    AgglomerativeClustering
)

# Modell erstellen
model = AgglomerativeClustering(
    n_clusters=3,
    linkage='ward'
)

# Cluster-Labels erhalten
labels = model.fit_predict(X)

# Ergebnis prüfen
print(labels)
# [0 0 1 1 2 2 ...]
```

FAZIT & AUSBLICK

Hierarchisches Clustering löst das K-Problem durch einen vollständigen Clusterbaum

Ward-Linkage minimiert die Within-Cluster-Varianz → empfohlener Standard

Dendrogramme machen Clusterstrukturen auf allen Ebenen sichtbar

Grenzen: $O(n^2)$ Speicher, langsamer als K-Means, irreversible Merges

14